

# rPPG 도메인에서의 연합학습 적용 및 개인화 성능 비교 연구

## A comparative study of application of federated learning and personalization performance in the rPPG domain

Jinsoo Kim\*, Kwangkee Lee, Ph.D<sup>†</sup>

\* AI research team, TVstorm, Seoul 137875, wlstn25092303@tvstorm.com, kklee@tvstorm.com

**Abstract:** As the demand for telemedicine increases, research interest in rPPG has also increased. However, the face data used by rPPG always raises the issue of privacy. In this paper, federated learning is applied to efficiently solve these rPPG problems and improve performance. Through the application of federated learning, learning in a distributed environment to protect personal information and to learn a model similar to the existing performance was verified through experiments. Furthermore, it was confirmed that the convergence speed of the model for new clients can be improved through the meta-learning personalization technique.

**Keyword:** Federated Learning, rPPG, Remote PPG, Personalization

### I. 배경

연합학습(Federated Learning)은 분산된 클라이언트에서 소유하고 있는 데이터의 전송 없이 통합된 모델을 학습하는 방법이다. 기존의 인공지능 모델 학습에서 통합된 데이터셋을 구축하는 방식과 비교하였을 때, 연합학습은 다음과 같은 장점이 존재한다. 1) 분산된 클라이언트의 데이터가 아닌 모델의 가중치(weight)를 공유하기 때문에 개인정보 보호에 효과적이다. 2) 다양한 클라이언트의 데이터를 통해 학습될 수 있어서 모델의 다양성이 증가하고 일반화될 수 있다. 3) 데이터가 분산되어 있어서 대용량 저장소나 업로드 리소스 필요하지 않다. 위와 같은 장점으로 인하여 연합학습은 개인을 식별하거나 개인정보에 민감한 도메인에 효율적으로 사용될 수 있다. 특히, 생체 정보, 건강 데이터와 같은 의료 데이터 분야에서 높은 관심을 보이며 연구되고 있다[1].

최근 다양한 이슈와 함께 의료 분야에서 원격 의료 기술에 대한 수요가 증가하면서, 의료 기기 없이 RGB 카메라를 통하여 얼굴 모세혈관의 빛의 반사 수치를 통해 심박 호흡 등 다양한 생체 정보를 측정하는 rPPG(Remote PhotoPlethysmoGraphy) 분야에 관한 연구가 활발히 진행되고 있다[2-3]. rPPG 기술은 특별한 장치가 필요하지 않은 저비용의 장점과 스마트폰의 카메라를 통해서 항상 측정이 가능하다는 장점이 존재한다. 하지만 rPPG 기술 역시도 사용하는 데이터가 사람의 얼굴이기 때문에 개인 정보 보호와 사용자 데이터의 이질성에 따라 부정확성이 높아지는 문제가 있다.

이질성(Heterogeneity)에 대한 문제는 연합학습에서도 쟁점이 되고 있는 문제로써 모든 클라이언트에서 잘 작동되는 하나의 모델을 만들기 어려우며, 개

별 클라이언트에서 최적의 성능이 보장되지 않는다. 이 문제를 해결하기 위해서는 글로벌 모델뿐만 아니라 개인화·로컬 모델의 성능을 최적화할 수 있는 연합학습 기술 필요하다.

본 연구에서는 딥러닝 기반의 rPPG 모델에 연합학습을 적용하여 rPPG 기술의 문제점 해결에 대한 가능성을 확인하고, 연합학습과 rPPG 기술의 공통적인 문제점인 개별 클라이언트의 데이터 이질성 문제 해결을 위해 메타러닝(Meta Learning)을 적용한 개인화 기술을 통해 향상된 성능을 확인하였다.

### II. 방법

본 연구는 다음 순서로 진행된다. 세션1에서는 rPPG에 대한 원리에 대해 설명한다. 세션2에서는 실험에 사용된 모델과 오픈 데이터셋 및 전처리 방식에 대해 설명한다. 세션3에서는 연합학습 적용에 대한 실험 환경과 개인화 기술에 대해 설명한다.

#### 1. rPPG(Remote PhotoPlethysmoGraphy)

rPPG 기술은 기존 Oximeter를 사용해 측정해오던 PPG 신호의 측정 방법을 카메라 기반의 이미지를 통해 측정할 수 있도록 설계된 기술이다. 얼굴 내부에 있는 모세혈관 속 혈류의 흐름에 반사되는 빛의 양을 통해 심박수(BPM), 호흡수(SpO2), 심박 변이도(HRV) 등 다양한 생체 신호를 추정한다. 현재 rPPG 기술은 이미지의 RGB 채널 필터 및 주파수 분석을 통해 생체 정보를 추출하는 전통적인 방식과 최근 활발히 연구되는 딥러닝 모델을 활용한 방법이 있으며, 딥러닝 방식에도 2D-CNN, 3D-CNN, STMAP, ViT 등 다양한 접근 방식들이 존재한다.

## 2. 모델 및 데이터셋

본 연구에서 사용한 모델은 3D-CNN 기반의 PhysNet 모델이다[4]. PhysNet 모델의 특성은 비디오의 Temporal과 Spatial에 대한 feature를 다른 특수한 전처리 없이 3D-CNN을 통해 처리한 부분과 Encoder 구조와 손실 함수 Negative Pearson Loss Function을 이용하여 End-to-End 생체 신호 추정 보다는 Raw PPG 신호 추정에 집중한 부분이다.

학습 데이터는 rPPG 실험을 위한 오픈 데이터셋인 UBFC를 이용하였다. 2명의 흑인과 1명의 황인 그리고 나머지 백인으로 구성된 40명 실험자이며, 30 fps의 성능으로 약 1분가량 수집되었다. label의 경우 각 영상에 맞도록 PPG 신호가 수집되어있다.

## 3. 실험 환경

실험 환경은 다음과 같다. 연합학습 환경을 셋팅을 위하여 연합학습 오픈 프레임워크 Flower와 FedAvg를 이용하였다. UBFC 데이터셋의 40명 중 30명을 학습데이터, 그리고 나머지 10명을 테스트 데이터로 이용하였다. 연합학습의 분산된 모델 학습 환경에서는 학습데이터 30명을 각각 분산된 클라이언트로 데이터를 분배하였고, 라운드마다 새로운 클라이언트가 테스트 데이터를 가지고 모델 성능을 테스트하였다.

개인화를 위한 메타러닝 방법으로는 모든 모델에 사용할 수 있는 MAML(Model agnostic meta learning) 이용하였다. MAML 적용을 위해 데이터셋을 Support Set과 Query Set으로 각각 2:8 비율로 분배하였다.



Figure 1. Setting up the federated learning experiment environment

## III. 결 과

본 논문의 실험은 다음과 같으며 아래의 순서대로 결과를 비교한다.

1. 통합된 모델 학습의 결과와 연합학습이 적용된 분산된 모델 학습의 결과를 비교한다.

2. 연합학습이 적용된 분산된 모델 학습에서 로컬 업데이트의 결과를 비교한다.

3. 연합학습과 개인화를 위한 메타러닝이 적용된 결과를 비교한다.

## 1. Centralized learning vs Federated Learning

통합된 환경에서 학습된 모델의 경우 Figure 2에서 보이는 것처럼 본 연구의 모든 실험 중 가장 높은 정확도를 보였다. 연합학습이 적용된 분산된 환경에서 학습된 모델의 경우 통합된 환경의 모델보다 Pearson 상관계수가 0.45 낮은 정확도를 보였다. 하지만 이와 같은 차이는 Figure 3과 같이 PPG 파형에서 차이를 구분하기 어렵고 심박수, 호흡수 등 2차 가공의 형태에서 큰 차이를 보이지 않았다. 그리고 현재 사용하고 있는 FedAvg는 가장 기본적인 연합학습의 알고리즘으로 꾸준히 연구되고 있는 다양한 알고리즘들을 사용한다면 더욱 높은 성능을 기대할 수 있다. 본 실험에서는 분산된 환경에서 개인 민감 정보를 공유하지 않는 연합학습의 장점을 생각하면 rPPG 도메인에서의 연합학습 적용의 가능성을 볼 수 있었다.

## 2. 클라이언트 로컬 모델 업데이트

연합학습은 라운드마다 클라이언트의 로컬 모델을 업데이트하여 통합한다. 로컬 모델의 업데이트는 연합학습의 학습 시간과 컴퓨터 리소스를 결정하는 중요한 요소이다. Figure 2의 결과에서 볼 수 있듯이 각 로컬 모델 업데이트의 Epoch는 초기 1, 2, 10, 30, 50에서는 꾸준히 성능이 향상한다. 하지만 Epoch를 100까지 늘려 실험을 진행한 결과 학습 시간은 2배 이상 증가했지만, 학습 성능은 Epoch 50과 동등한 것을 확인하였다. rPPG 도메인에서 로컬 업데이트 횟수는 초기는 유의미하지만, 점차 한계치가 존재한다.

## 3. 개인화 적용 연합학습

연합학습의 개인화 방법 중 메타러닝을 적용한 결과는 Figure 3에서 볼 수 있듯이 모델의 성능에는 큰 차이가 존재하지 않는다. 하지만 Figure 3에서 두 모델의 결과를 보면 메타러닝을 적용한 모델이 기존의 모델보다 훨씬 빠른 수렴 속도를 보이는 것을 확인할 수 있다. 이 결과는 새로운 클라이언트가 연합학습에 참여하게 되었을 때, 새로운 클라이언트의 특성에 모델이 빠르게 적응할 수 있다는 점이다. 뿐만 아니라 메타러닝(Few-Shot Learning)을 적용했기 때문에 새로운 클라이언트가 가지고 있는 데이터의 수가 다른 클라이언트보다 적었을 때 기존의 모델보다 좋은 성능을 보일 수 있다.




Figure 4. Federated Learning and Centralized Learning Experiment Results Graph




Figure 5. Comparison FedMeta vs Federated learning

#### IV. 결 론

본 논문에서는 사람의 얼굴 데이터를 사용하는 rPPG 기술의 민감한 개인 정보와 사람마다 다른 얼굴과 측정 환경에서의 데이터 이질성을 연합학습의 분산된 환경에서의 학습이 가능하다는 장점과 개인화 기술을 통해 해결하고자 검증 실험을 진행하였다.

기존의 인공지능 모델의 학습 방법인 통합된 환경에서의 모델 학습과 연합학습의 분산된 환경에서의 학습에서는 통합된 환경에서의 모델의 성능이 미세하게 높았지만, 실제 추정된 파형의 형태에서 그 차이를 찾기 어려웠다. 연합학습의 핵심 파라미터인 로컬 업데이트에서도 초기 업데이트의 횟수에 따라 성능이 향상하는 듯 보였지만 한계점이 존재한다는 것을 확인하였다. 연합학습의 개인화를 위한 메타러닝 적용 실험에서는 개인화 적용 모델의 경우 기존 연합학습 모델과 성능에서는 큰 차이를 보이지 않았지만 매우 빠른 수렴 속도의 성능 차이를 보였다.

위 실험의 결과로 rPPG 도메인에서 연합학습은 많은 단점을 보완하고 높은 효율성을 기대할 수 있는 분야라고 생각된다. 하지만 본 논문의 실험에서는 다양한 모델과 학습 데이터셋을 사용하지 못했고, 연합학습의 FedAvg만을 사용했다는 한계점이 존재하

Table 1. Comparison table of Pearson correlation coefficients by local model update(epoch)

Local Model Update (epoch)	Pearson Correlation Coefficient
1	0.95
2	0.92
3	0.88
4	0.85
5	0.82
6	0.78
7	0.75
8	0.72
9	0.68
10	0.65
11	0.62
12	0.58
13	0.55
14	0.52
15	0.50
16	0.48
17	0.45
18	0.42
19	0.40
20	0.38
21	0.35
22	0.32
23	0.30
24	0.28
25	0.25
26	0.22
27	0.20
28	0.18
29	0.15
30	0.12
31	0.10
32	0.08
33	0.05
34	0.02
35	0.00



Figure 4. Inference rPPG of Centralized learning and Federated learning

기 때문에 지속적인 연구를 통해 더 많은 검증이 진행되어야 할 것이다.

#### 참고문헌

1. Liu, X., Zhang, M., Jiang, Z., Patel, S., & McDuff, D. (2022). Federated Remote Physiological Measurement with Imperfect Data. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (pp. 2155-2164).
2. Kim, D. Y., Lee, K., & Sohn, C. B. (2021). Assessment of ROI Selection for Facial Video-Based rPPG. *Sensors*, 21(23), 7923.
3. Kim, D., Kim, J., & Lee, K. (2021). Real-time Vital Signs Measurement System using Facial Image Data. *Journal of Broadcast Engineering*, 26(2), 132 - 142. <https://doi.org/10.5909/JBE.2021.26.2.132>
4. Yu, Z., Li, X., & Zhao, G. (2019). Remote photoplethysmograph signal measurement from facial videos using spatio-temporal networks. *arXiv preprint arXiv:1905.02419*.
5. Finn, C., Abbeel, P., & Levine, S. (2017, July). Model-agnostic meta-learning for fast adaptation of deep networks. In International conference on machine learning (pp. 1126-1135). PMLR.

#### 사사

이 논문은 2021년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 연구임(No. 2021-0-00900)