Deep Learning Overview

김 대 열 2022.09.02

AL vs ML vs DL

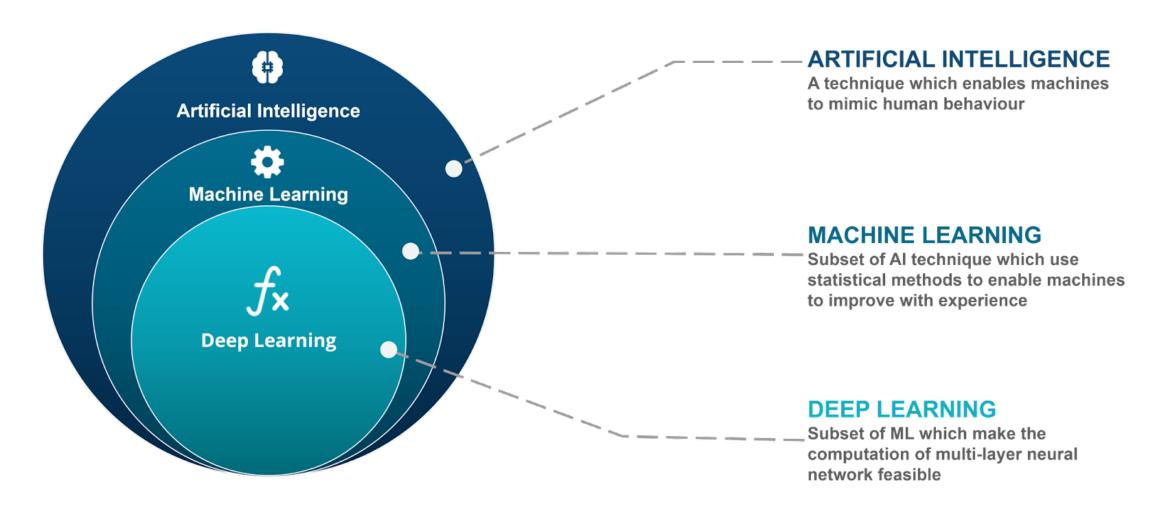
- AI(Artificial Intelligence)
 - 사람이 할 수 있는 일을 대신하는 것을 통칭
- ML(Machine Learning)
 - AI의 종류 중 하나로 수 많은 데이터셋을 이용하여 동작
- DL(Deep Learning)
 - ML 방식 중 하나로 MLP(Multi Layer Perceptron)을 이용한 방식

강사 소개

- 김대열
- Tvstorm AI 개발팀 팀장
- 주요 연구 분야 : 생체 신호 분석, 영상처리

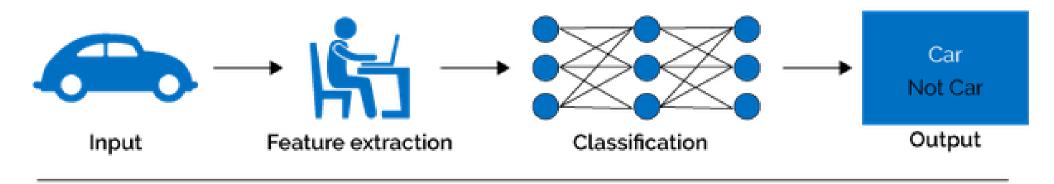
• Email : kwelcomm@gmail.com

AL vs ML vs DL

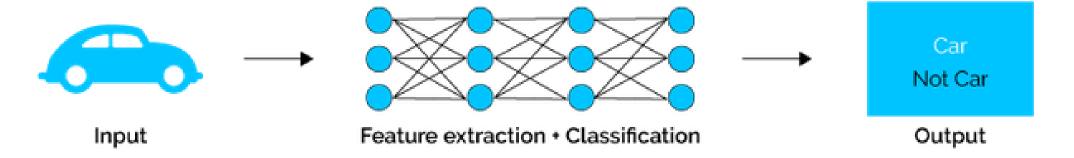


ML vs DL

Machine Learning

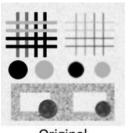


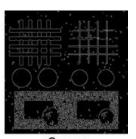
Deep Learning

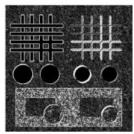


ML vs DL

- ML
- 데이터의 어떤 특징을 어떻게 뽑아 냈는 가가 결과를 바꿈
 - Ex) 영상처리
 - 어떤 특징 : 외곽선 추출, 특징 점 추출.. 등
 - 어떻게
 - 외곽선 추출 : 어떤 필터를 썻는가
 - Laplace filter, sobel filter, Canny Edge
 - 특징 점 추출 : 어떤 특징 점 추출 방식을 사용했는가
 - SIFT, Harris Corner







Original

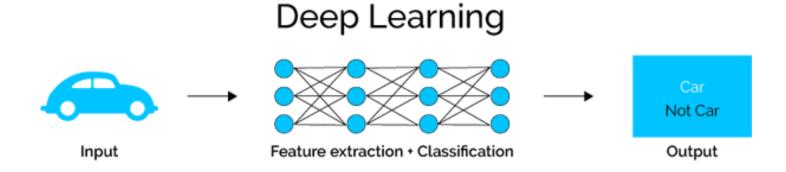
Laplacian

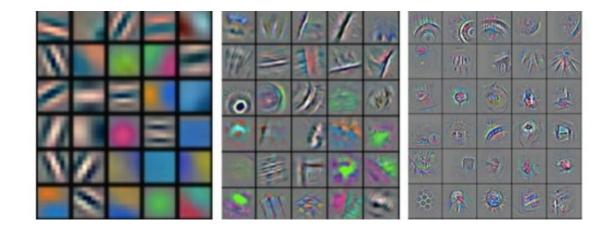
Canny

Sobel X+Y

ML vs DL

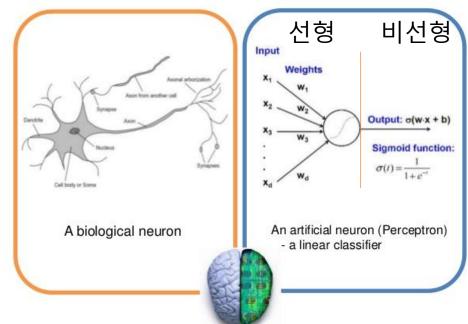
• DL





DL

- Deep Learning(Deep Neural Network)이란?
 - Neural Network
 - 인간의 뇌를 모방한 알고리즘으로써 뇌의 최소 구성단위인 Neuron을 본 뜬 Perceptron으로 구성

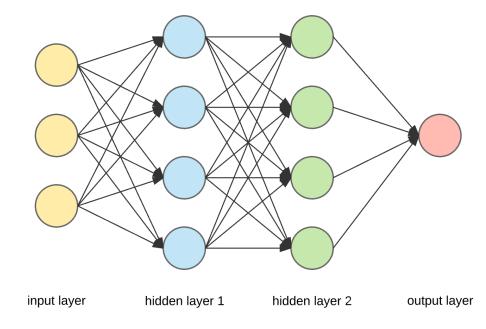


DL

- Deep Learning(Deep Neural Network)이란?
 - Deep Neural Network

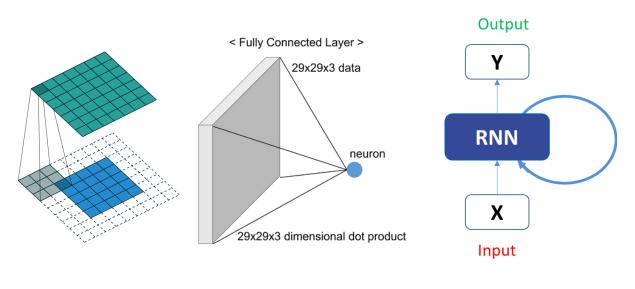
• Perceptron으로 이루어진 Hidden Layer가 두 개 층 이상 존재하면

Deep Neural Network라 칭함



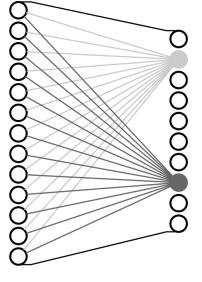
Components of DL

• Deep Learning은 Neuron으로 만들어진 다양한 Layer의 조합과 비선형 식의 조합으로 분류 능력이 뛰어난 알고리즘을 생성할 수 있음.

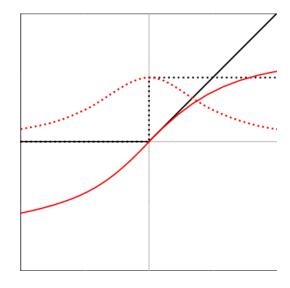


<Convolution Layer> 이미지 Feature 추출

<Recurrent Neural network> 시계열 data Feature 추출



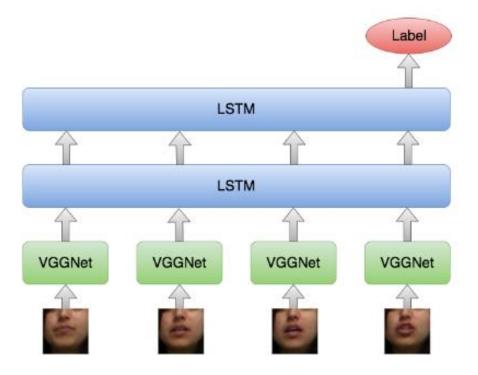
Input Weights Output <Fully Connected Layer> Input을 이용하여 분류



<Activation Function> 모델의 비선형성 증가

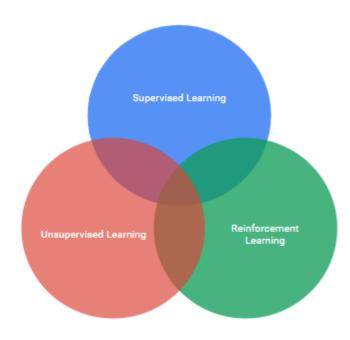
Components of DL

• Ex) Lip reading Model



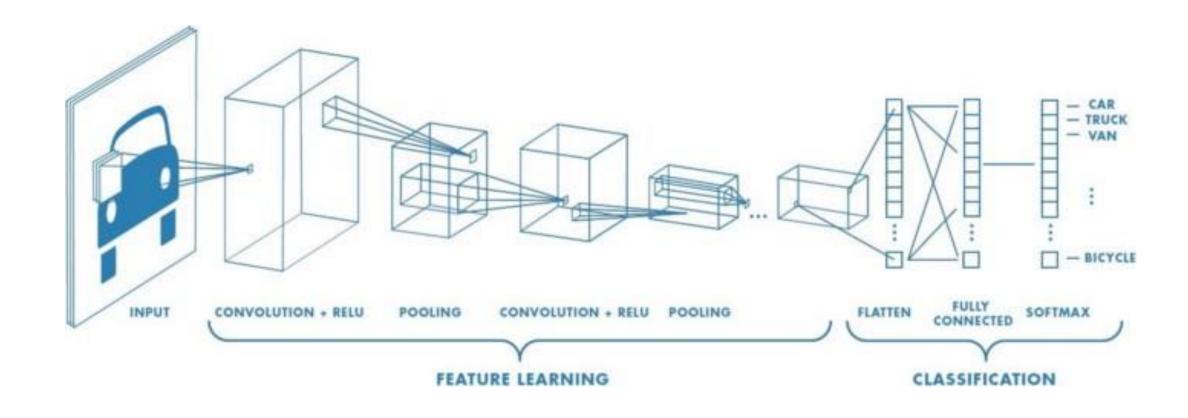
Types of ML

- 데이터에 따라 크게 3가지 분류의 학습 방법을 가진다
 - Supervised Learning ← rPPG
 - 데이터와 레이블이 있을 때 { X : Y }
 - Unsupervised Learning
 - 데이터만 있을때 {X}
 - Reinforcement Learning
 - 행동에 대한 결과(Reward)가 있을 때 { X : R }
- 추가적으로 데이터의 레이블이 일부 있을 때 Semi-supervised Learning 학습법을 이용한다.



Deep Learning Trend

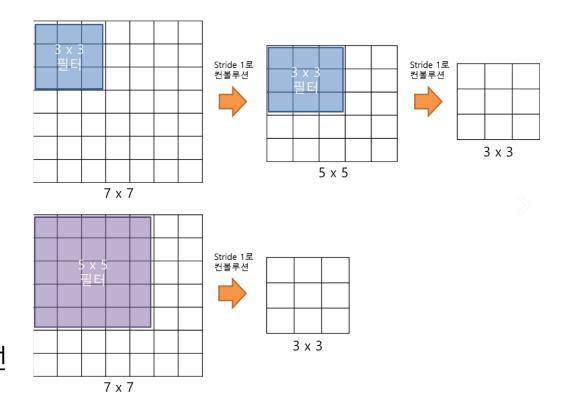
Visual (Conv -> Batch) x N -> (1x1Conv, BN, Relu) -> 이미지 데이터 (1x inTransformer (3x3DWConv, BN, Relu) -> Activation Conv)outConv (1x1Conv, BN, Relu) -> Dropout -> Pooling VGG Style MBConv Style Vit ResNet Style 시계열 데이터 Positional Encoding + Attention 1D Conv x N -> LSTM/GRU x2 LSTM/GRU Transformer Conv + RNN **Traditional** 비디오 데이터 CNN + LSTM/GRU STMap Visual Transformer 3D Conv **RCNN Style** Vit STMap 3DConv



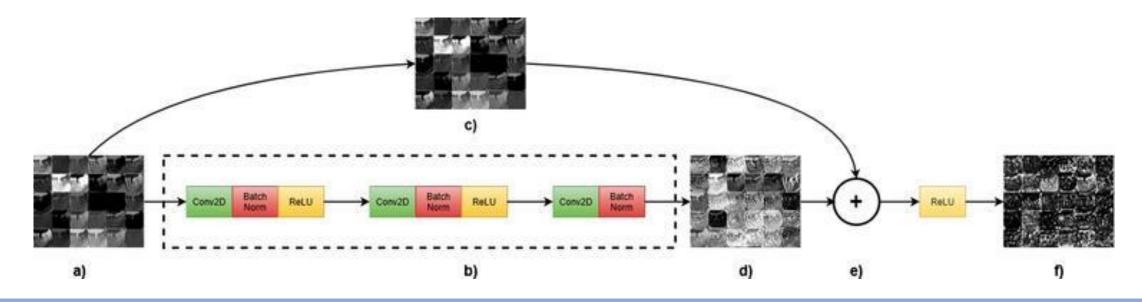
- Lenet style -> VGG style
 - LENET은 7x7 filter를 사용
 - → 많은 파라미터를 사용
 - VGG 는 7x7대신 3x3 세 번 사용

- 7x7 filter의 49개의 파라미터
 - → 3x3 filter 3개는 9x3개의 파라미터

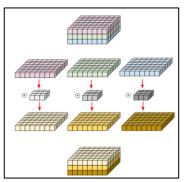
49 → 27 개로 획기적으로 파라미터 개선

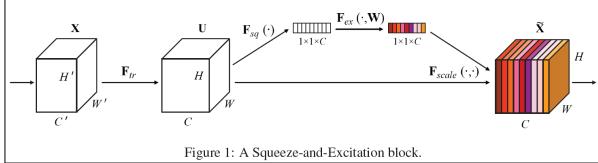


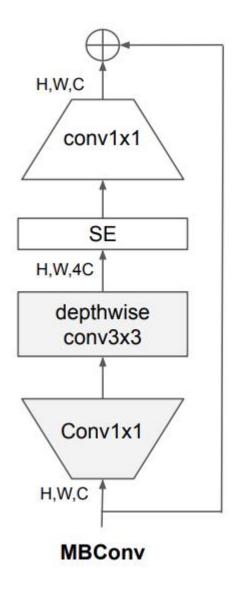
- VGG style -> Resnet Style
 - VGG Style은 Deep 하게 쌓을 수록 학습이 안되는 문제를 갖고 있음
 - Conv 연산 전의 Feature를 유지 함으로써 Conv연산을 통해 소실된 데이터를 없애는 특징을 가짐



- Resnet Style -> MB Conv Style
 - Depthwise Network 이용
 - Convolution이 모든 채널의 정보를 이용하는 점 때문에 Spatial한 정보를 취득하지 못하는 문제를 해결하기 위해 적용
 - SE(Squeeze & Excitation) Network를 이용
 - Squeeze
 - 전체 Filter를 대표하는 값을 추출 하는 역할
 - Excitation
 - one-hot activation이 아닌 다중 강조





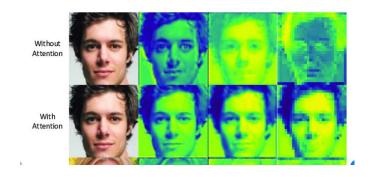


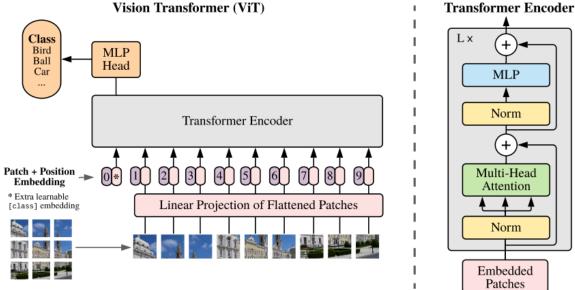
17

- MB Conv Style -> ViT Style
 - ViT 이용
 - Convolution이 Local feature를 뽑기 때문에, 전체적인 특징을 뽑아내지 못하는 문제를 해결

Component	Entities	Relations	Rel. inductive bias	Invariance
Fully connected	Units	All-to-all	Weak	-
Convolutional	Grid elements	Local	Locality	Spatial translation
Recurrent	Timesteps	Sequential	Sequentiality	Time translation
Graph network	Nodes	Edges	Arbitrary	Node, edge permutations

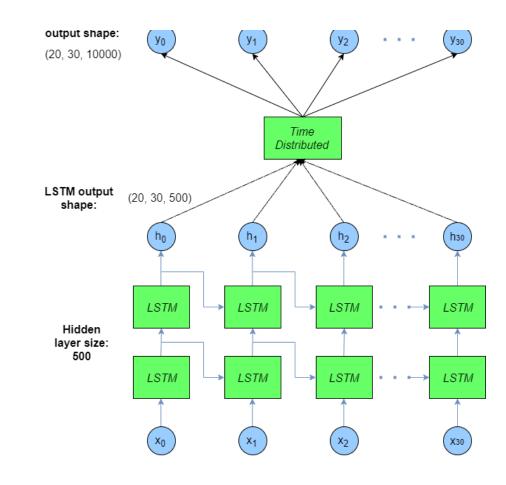
Table 1: Various relational inductive biases in standard deep learning components. See also Section 2.





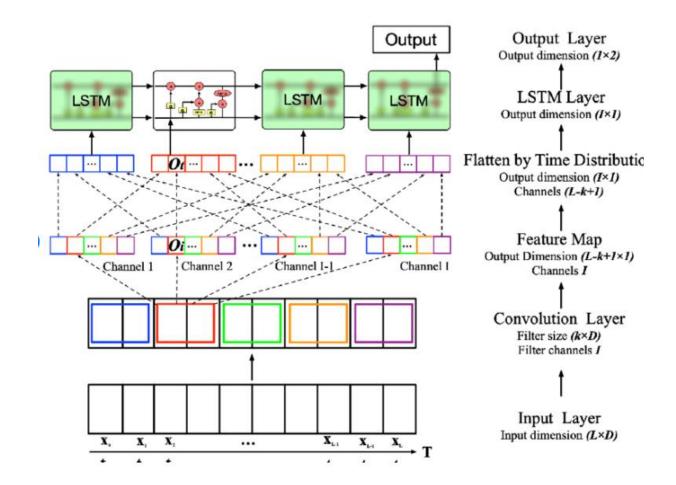
Timeseries processing history

- RNN Style
 - LSTM x2 + Dense 구조
 - 시계열 Feature를 구한 다음 Dense 구조
 - 기존의 LSTM 모델이 **이전의 데이터를 소실** 하는 특정이 있기 때문에 두 레이어를 쌓아 **양방향** 특징 을 뽑아 내고지 함



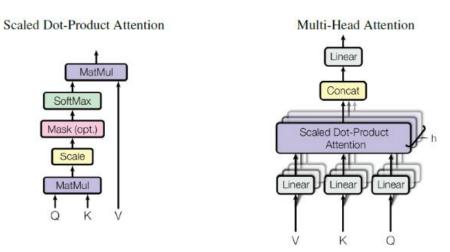
Timeseries processing history

- RNN Style => Conv + RNN 구조
 - 1D CNN을 이용
 - Local Feature를 뽑아 여러 입력에 의해 값이 바뀔 수 있도록 구조 변경



Timeseries processing history

- Conv + RNN 구조 =>Positional Encoding + Attention
 - LSTM의 정보가 소실 되는 문제를 FC로 해결
 - Scaled Dot-product Attention을 통해 각 형태소의 특징 강화



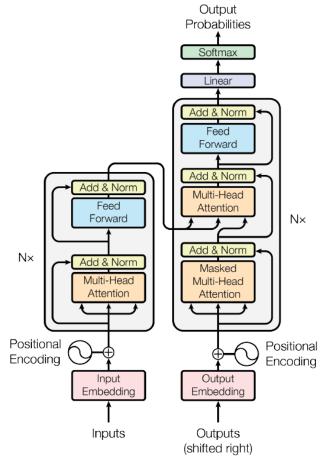


Figure 1: The Transformer - model architecture.

- Conv + LSTM
 - CNN을 통해 Feature Sequence 추출
 - Feature를 조합하여 LSTM으로 이미지 시퀀스 예측

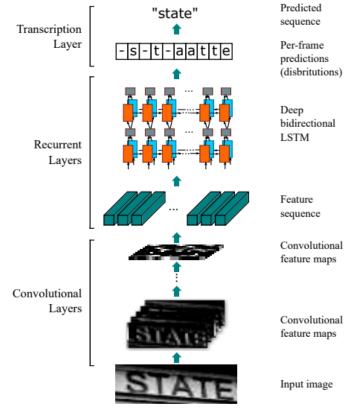
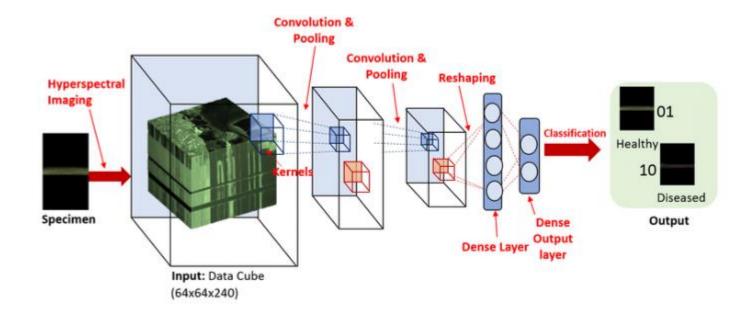
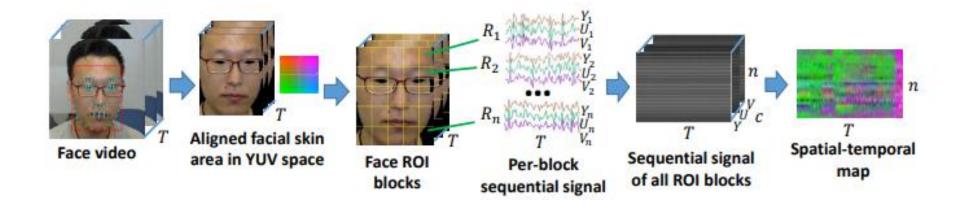


Figure 1. The network architecture. The architecture consists of three parts: 1) convolutional layers, which extract a feature sequence from the input image; 2) recurrent layers, which predict a label distribution for each frame; 3) transcription layer, which translates the per-frame predictions into the final label sequence.

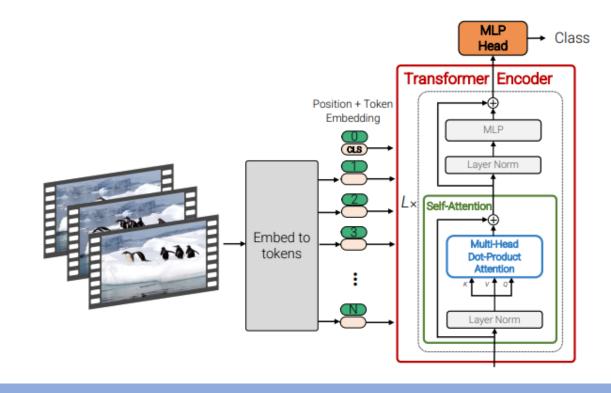
- Conv + LSTM => 3D CNN
 - LSTM의 Feature가 소실 되는 문제 해결
 - 2D(WxH)에 T(시간)을 추가하여 시 공간적인 특성을 해결하고자 함



- 3D CNN => STMAP
 - 3D CNN의 파라미터가 많아 학습 속도가 느린 문제를 해결
 - 시간적인 특징에 더욱 집중하여, 시계열 정확도를 높임



- STMAP => ViT
 - 각 이미지를 position 토큰으로 변환하여 성능 향상

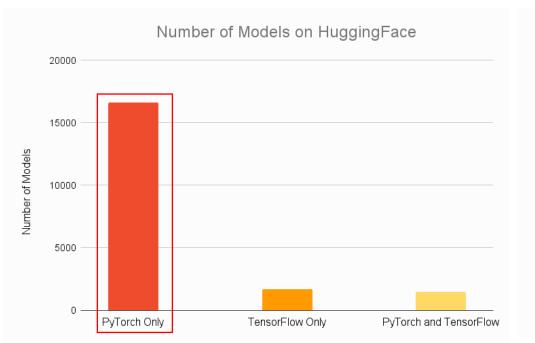


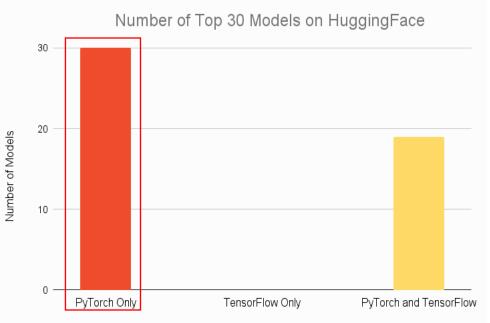
Deep Learning Trend

Visual (Conv -> Batch) x N -> (1x1Conv, BN, Relu) -> 이미지 데이터 (1x inTransformer (3x3DWConv, BN, Relu) -> Activation Conv)outConv (1x1Conv, BN, Relu) -> Dropout -> Pooling VGG Style MBConv Style Vit ResNet Style 시계열 데이터 1D Conv x N -> LSTM/GRU x2 Positional Encoding + Attention LSTM/GRU Transformer Conv + RNN **Traditional** 비디오 데이터 CNN + LSTM/GRU STMap Visual Transformer 3D Conv **RCNN Style** Vit STMap 3DConv

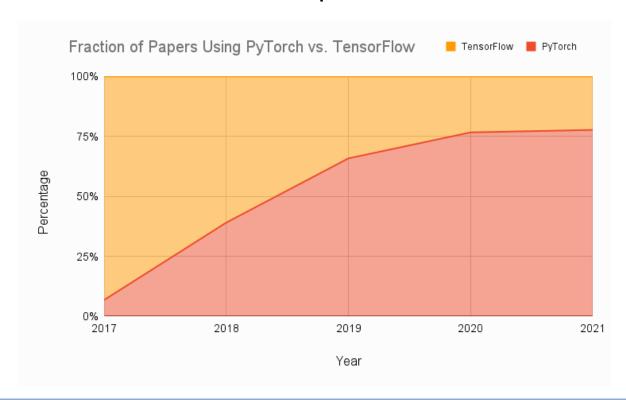
- Tensorflow vs PyTorch
 - https://www.assemblyai.com/blog/pytorch-vs-tensorflow-in-2022/
- 고려사항
 - 모델 가용성
 - 새로운 SOTA 알고리즘들이 얼마나 활용 가능한가
 - 배포 인프라
 - 훈련된 모델을 얼마나 쉽고 사용 할 수 있다
 - 생태계
 - PC기반이 아닌 다른 특수한 생태계에서 통합 가능성이 있는가

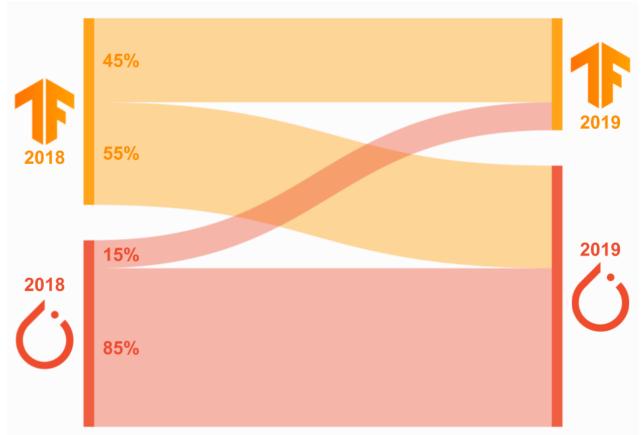
- 모델 가용성
 - Hugging Face : Transformer 기반으로 하는 다양한 모델의 학습 스크립트가 구현된 모듈



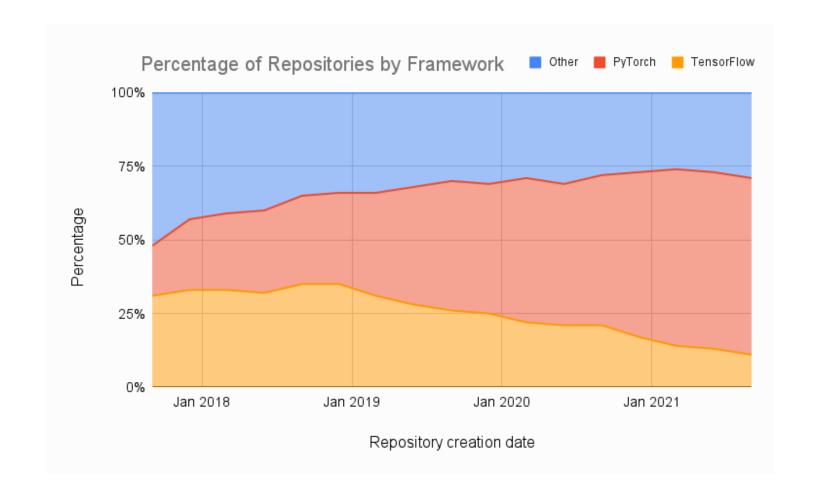


- 모델 가용성
 - Research Paper

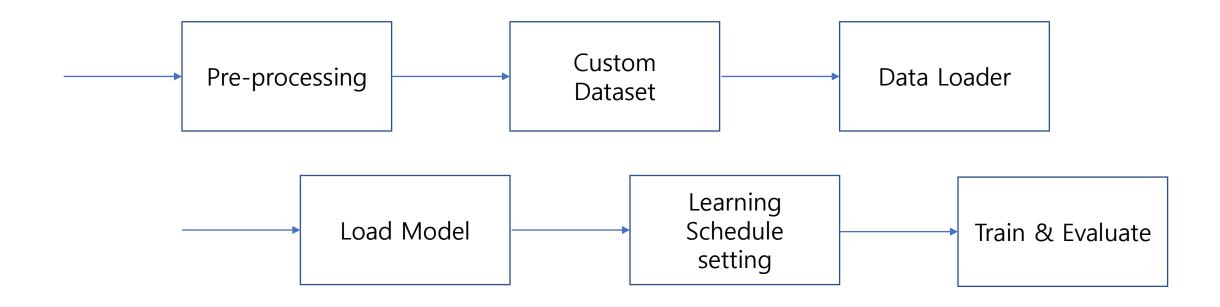




- 모델 가용성
 - Papers with Code



- 초보자라면..
 - TF v2(Keras)를 이용해서 딥러닝 연습 후 Pytorch 로 넘어 가는 것 추천



- Preprocessing
 - 데이터 preprocessing은 모델이 풀어야하는 문제를 좀더 쉽게 정의
 - 학습 수렴 속도/성능의 향상
 - Ex) data slicing, Normalization

- Custom Dataset
 - 원하는 목적을 가지는 모델을 학습시키기 위해선 Dataset을 원하는 형태로 구성이 가능 하여야 함
 - 구성 요소
 - def __init__
 - def __getitem__
 - def __len__

```
from torch.utils.data import Dataset
class CustomDataset(Dataset):
  def __init__(self, x, y):
    self.x data = x
    self.v data = v
  def __getitem__(self,idx):
    x = torch.Tensor(self.x data[idx])
    y = torch.Tensor(self.y data[idx])
    if torch.cuda.is available():
      return x.to('cuda'), y.to('cuda')
    return x,y
  def __len__(self):
    return len(self.x_data)
```

- DataLoader
 - Dataset을 딥러닝 모델 학습에 편한 형태로 제공하기 위해 객체로 감쌈
 - Batch size, shuffle
 - 일반적으로 데이터셋은 trainset: testset = 80:20 으로 이용

- Load Model
 - 데이터셋의 입력/출력 형태에 맞게 모델 생성
 - torch.nn.Module 상속
 - def __init__(self):
 - 네트워크 레이어 등 각종 변수 선언
 - def forward(self, x):
 - 네트워크 레이어 연결

```
import torch
class Network(torch.nn.Module):
   def __init__(self):
        super().__init__()
        self.densel = torch.nn.Linear(2,10)
        self.dense2 = torch.nn.Linear(10,2)
   def forward(self, input)
        x = self.densel(input)
        x = self.dense2(x)
        return x
```

Deep Learning 학습 절차

- Learning Schedule Setting
 - 모델의 optimizer/ Ir 등 다양한 정보 세팅

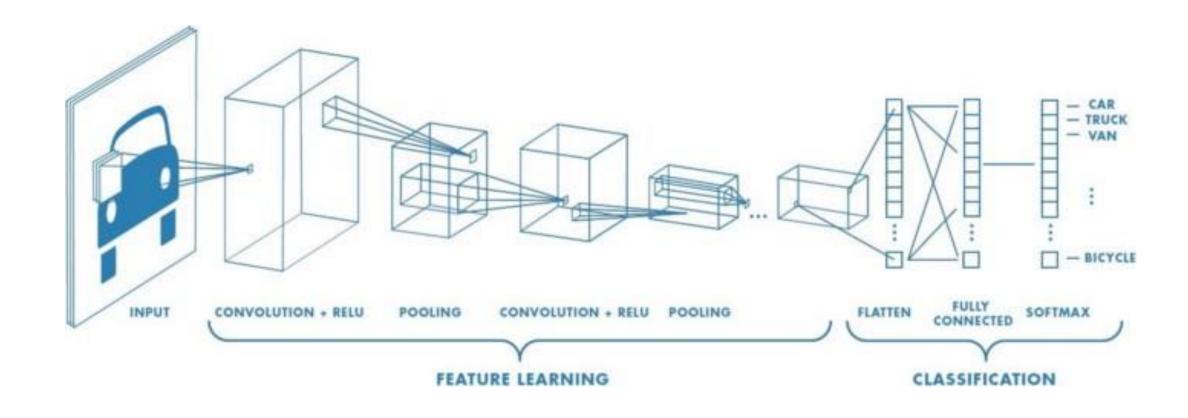
```
import torch.nn.modules.loss as loss
import torch.optim as opt
import torch.optim import lr_scheduler

model = Network().to('cuda')
criterion = loss.MSELoss()
optimizer = opt.Adam(model.parameters, lr = 0.001, weight_decay = 0.0005)
scheduler = lr_scheduler.ExponentialLR(optimizer, gama=0.99)
```

Deep Learning 학습 절차

Train & evaluate

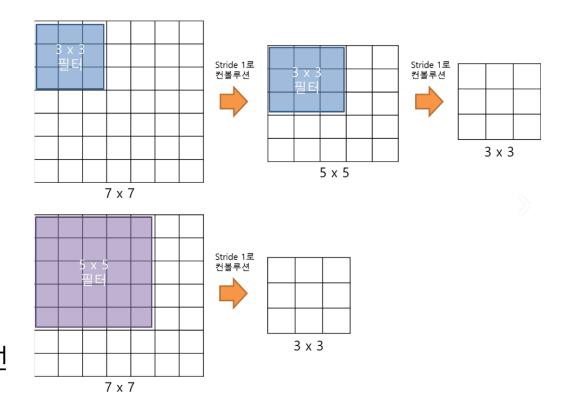
```
for e in range(epoch):
   with tgdm(train_loader, desc="Train",total=len(train_loader)) as tepoch:
     model.train()
                                                     model.eval()
     running loss=0.0
                                                     running loss=0.0
     for inputs, label in tepoch:
                                                     for inputs, label in tepoch:
       outputs = model(inputs)
                                                       outputs = model(inputs)
       loss = criterion(outputs, label)
                                                       loss = criterion(outputs, label)
       optimizer.zero_grad()
       loss.backward()
       running loss += loss.item()
       optimizer.step()
```



- Lenet style -> VGG style
 - LENET은 7x7 filter를 사용
 - → 많은 파라미터를 사용
 - VGG 는 7x7대신 3x3 세 번 사용

- 7x7 filter의 49개의 파라미터
 - → 3x3 filter 3개는 9x3개의 파라미터

49 → 27 개로 획기적으로 파라미터 개선

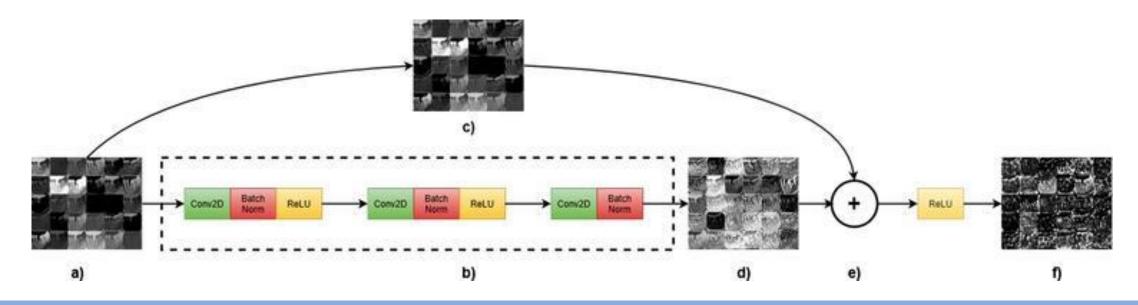


Lenet style -> VGG style

```
import torch
class LeNet(torch.nn.Module):
   def init (self):
       super().__init__()
       self.feature block = torch.nn.Sequential(
            torch.nn.Conv2d( 1, 6,kernel_size = 5, stride=1),
            torch.nn.Tanh(),
            torch.nn.AvgPool2d(kernel_size=2,stride=2),
            torch.nn.Conv2d( 6, 16,kernel_size = 5, stride=1),
            torch.nn.Tanh(),
            torch.nn.AvgPool2d(kernel size=2,stride=2),
            torch.nn.Conv2d(16, 120, kernel siz e= 5, stride=1),
            torch.nn.Tanh(),
            torch.nn.Flatten()
       self.dense = torch.nn.Sequential(
            torch.nn.Linear(120, 84),
            torch.nn.Linear(84,10)
    def forward(self,x):
       x = self.feature block(x)
       x = self.dense(x)
        return x
```

```
import torch
class VGGStyle(torch.nn.Module):
    def __init__(self):
        super(). init ()
        self.feature_block = torch.nn.Sequential()
            torch.nn.Conv2d( 1, 6,kernel size = 3, stride=1),
            torch.nn.Conv2d( 6, 6,kernel size = 3, stride=1),
            torch.nn.Tanh(),
            torch.nn.AvgPool2d(kernel_size=2,stride=2),
            torch.nn.Conv2d( 6, 16,kernel size = 3, stride=1),
            torch.nn.Conv2d( 16, 16, kernel size = 3, stride=1),
            torch.nn.Tanh(),
            torch.nn.AvgPool2d(kernel size=2,stride=2),
            torch.nn.Conv2d(16, 120, kernel siz e= 3, stride=1),
            torch.nn.Conv2d(120, 120, kernel siz e= 3, stride=1),
            torch.nn.Tanh(),
            torch.nn.Flatten()
        self.dense = torch.nn.Sequential(
            torch.nn.Linear(120, 84),
            torch.nn.Linear(84,10)
    def forward(self,x):
        x = self.feature block(x)
        x = self.dense(x)
        return x
```

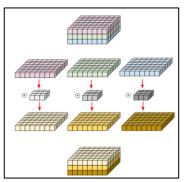
- VGG style -> Resnet Style
 - VGG Style은 Deep 하게 쌓을 수록 학습이 안되는 문제를 갖고 있음
 - Conv 연산 전의 Feature를 유지 함으로써 Conv연산을 통해 소실된 데이터를 없애는 특징을 가짐

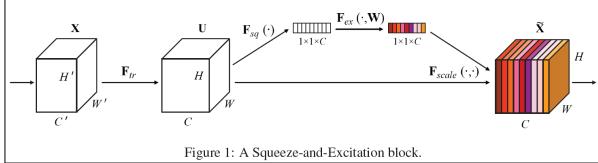


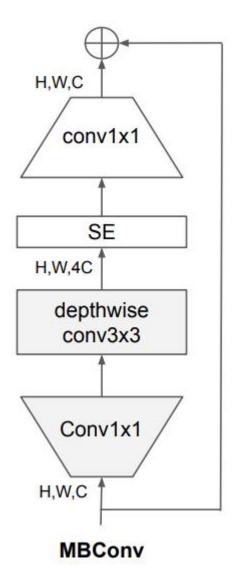
VGG style -> Resnet Style

```
import torch
class ResNetStyle(torch.nn.Module):
   def __init__(self):
        super(). init ()
        self.feature block = torch.nn.Sequential(
            torch.nn.Conv2d(120,120, kernel_size=3, stride = 1)
        self.block = torch.nn.Conv2d(120,120,kernel_size=1, stride = 1)
        self.dense = torch.nn.Sequential(
            . . .
   def forward(self,x):
        x = self.feature_block(x)
       x = self.block(x) + x
       x = self.dense(x)
        return x
```

- Resnet Style -> MB Conv Style
 - Depthwise Network 이용
 - Convolution이 모든 채널의 정보를 이용하는 점 때문에 Spatial한 정보를 취득하지 못하는 문제를 해결하기 위해 적용
 - SE(Squeeze & Excitation) Network를 이용
 - Squeeze
 - 전체 Filter를 대표하는 값을 추출 하는 역할
 - Excitation
 - one-hot activation이 아닌 다중 강조







Resnet Style -> MB Conv Style

```
import torch
from einops import rearrange
from einops.layers.torch import Rearrange, Reduce
class MBconvStyle(torch.nn.Module):
   def __init__(self):
        super(). init ()
        self.feature block = torch.nn.Sequential(
            torch.nn.Conv2d(120,20, kernel_size=1)
           torch.nn.BatchNorm2d(20),
            torch.nn.SiLU(),
           torch.nn.Covn2d(20,20,kernel size=3,stride=1),
           SEBlock(dim=20,shrinkage rate=0.25),
            torch.nn.Conv2d(20,20, kernel_size=1),
            torch.nn.BatchNorm2d(20)
        self.block = torch.nn.Conv2d(inchannel,20,kernel_size=1, stride = 1)
        self.dense = torch.nn.Sequential(
   def forward(self,x):
       x = self.feature block(x)
       x = self.block(x) + x
       x = self.dense(x)
        return x
```

```
class SEBlock(torch.nn.Module):
    def __init__(self, dim, shrinkage_rate = 0.25):
        super().__init__()
        hidden_dim = int(dim * shinkage_rate)

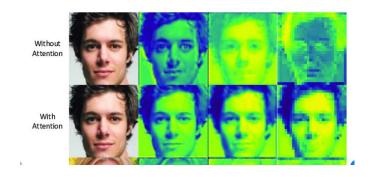
    self.gate = nn.Sequential(
        Reduce('b c h w -> b c', 'mean'),
        torch.nn.Linear(dim,hidden_dim, bias = False),
        nn.SiLU(),
        nn.Linear(hidden_dim, dim, bias = False),
        nn.Sigmoid(),
        Rearrange('b c -> b c 1 1')
    )

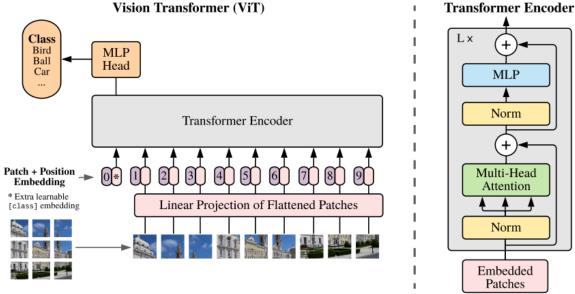
    def forward(self, x):
        return x * self.gate(x)
```

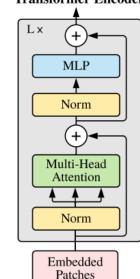
- MB Conv Style -> ViT Style
 - ViT 이용
 - Convolution이 Local feature를 뽑기 때문에, 전체적인 특징을 뽑아내지 못하는 문제를 해결

Component	Entities	Relations	Rel. inductive bias	Invariance
Fully connected	Units	All-to-all	Weak	-
Convolutional	Grid elements	Local	Locality	Spatial translation
Recurrent	Timesteps	Sequential	Sequentiality	Time translation
Graph network	Nodes	Edges	Arbitrary	Node, edge permutations

Table 1: Various relational inductive biases in standard deep learning components. See also Section 2.







- MB Conv Style -> ViT Style
 - ViT 이용

```
class ViT(nn.Module):
    def __init__(self, *, image_size, patch_size, num_classes, dim, depth, heads, mlp_dim, pool =
'cls', channels = 3, dim head = 64, dropout = 0., emb dropout = 0.):
        super().__init__()
        image_height, image_width = pair(image_size)
        patch_height, patch_width = pair(patch_size)
        num_patches = (image_height // patch_height) * (image_width // patch_width)
        patch_dim = channels * patch_height * patch_width
        self.to_patch_embedding = nn.Sequential(
            Rearrange('b c (h p1) (w p2) -> b (h w) (p1 p2 c)', p1 = patch_height, p2 = patch_width),
            nn.Linear(patch_dim, dim),
                                                                                            def forward(self, img):
                                                                                                x = self.to_patch_embedding(img)
        self.pos_embedding = nn.Parameter(torch.randn(1, num patches + 1, dim))
                                                                                               b, n, = x.shape
        self.cls_token = nn.Parameter(torch.randn(1, 1, dim))
        self.dropout = nn.Dropout(emb dropout)
                                                                                                cls tokens = repeat(self.cls token, '1 1 d -> b 1 d', b = b)
                                                                                                x = torch.cat((cls_tokens, x), dim=1)
        self.transformer = Transformer(dim, depth, heads, dim_head, mlp_dim, dropout)
                                                                                                x += self.pos_embedding[:, :(n + 1)]
                                                                                                x = self.dropout(x)
        self.pool = pool
        self.to_latent = nn.Identity()
                                                                                                x = self.transformer(x)
                                                                                                x = x.mean(dim = 1) if self.pool == 'mean' else x[:, 0]
        self.mlp_head = nn.Sequential(
            nn.LayerNorm(dim),
                                                                                                x = self.to latent(x)
            nn.Linear(dim, num classes)
                                                                                                return self.mlp_head(x)
```

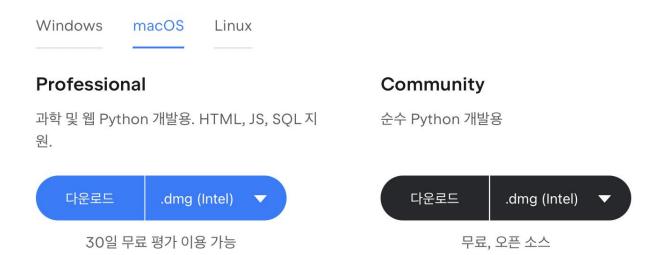
MB Conv Style -> ViT Style

```
class Attention(nn.Module):
    def __init__(self, dim, heads = 8, dim_head = 64, dropout = 0.):
        super().__init__()
        inner dim = dim head * heads
        project out = not (heads == 1 and dim head == dim)
        self.heads = heads
        self.scale = dim head ** -0.5
        self.attend = nn.Softmax(dim = -1)
        self.dropout = nn.Dropout(dropout)
        self.to_qkv = nn.Linear(dim, inner_dim * 3, bias = False)
        self.to_out = nn.Sequential(
            nn.Linear(inner_dim, dim),
            nn.Dropout(dropout)
        ) if project_out else nn.Identity()
    def forward(self, x):
        qkv = self.to_qkv(x).chunk(3, dim = -1)
       q, k, v = map(lambda t: rearrange(t, 'b n (h d) -> b h n d', h = self.heads), qkv)
        dots = torch.matmul(q, k.transpose(-1, -2)) * self.scale
        attn = self.attend(dots)
        attn = self.dropout(attn)
        out = torch.matmul(attn, v)
        out = rearrange(out, 'b h n d -> b n (h d)')
        return self.to out(out)
```

Dev env

- Pycharm professional
 학교 계정 활성화 및 사용

다운로드 PyCharm



Dev env

Plugin

for ver in range(10):

if ver == 0: # M(W@H)+M

elif ver == 2: # MW+M

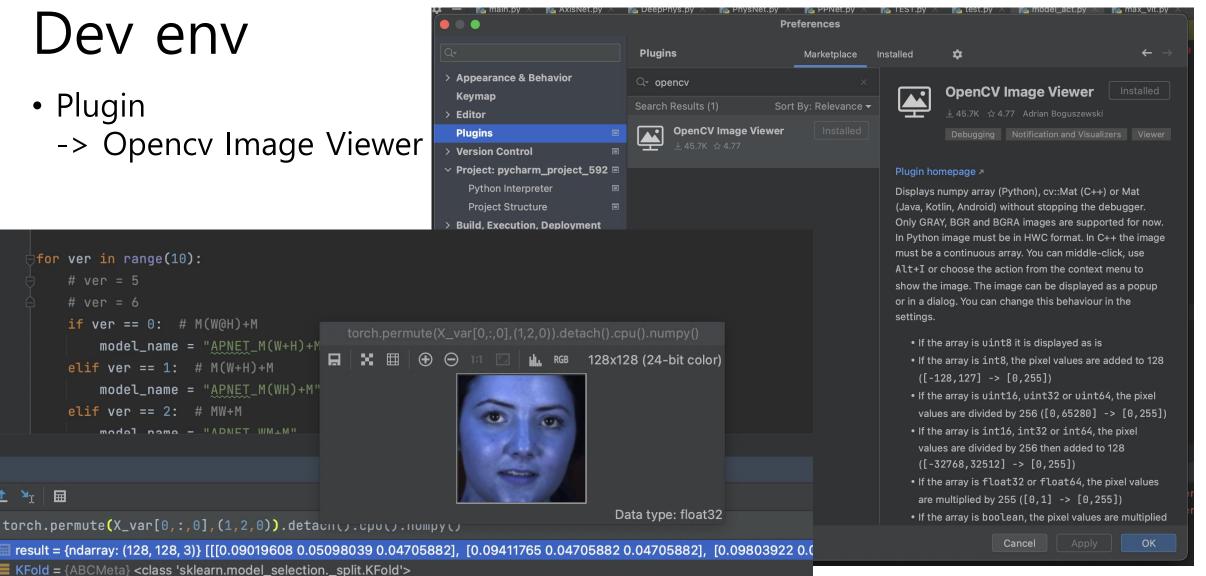
elif ver == 1: # M(W+H)+M

model_name = "APNET_M(W+H)+M

model_name = "APNET_M(WH)+M

model name - "ADMET WM+M"

-> Opency Image Viewer

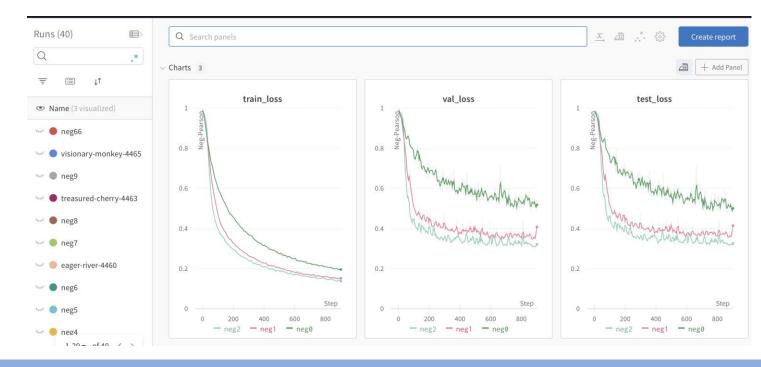


≥1 🖃

Dev env

Package

- Eniops: torch.reshape, permute 대체 차원 변환이 쉽고 용이
- Wandb : 학습 모니터링 툴, Hyperparmeter sweep, loss graph, model analysis 등 다양한 편리 기능 제공
- Tqdm: 파이썬 프로그레스바, 학습 상황 모니터링에 편리
- h5py: HDF 파일을 파이썬에서 사용 가능하도록 도와주는 파일. 파일의 계층 관리에 용이



REF

- https://www.edureka.co/blog/ai-vs-machine-learning-vs-deep-learning/
- https://mc.ai/machine-learning-vs-deep-learning-5/
- https://www.researchgate.net/figure/Effect-of-three-different-edge-detection-filters-Laplacian-Canny-and-Sobel-filters_fig5_236125496
- https://sacko.tistory.cohttps://sacko.tistory.com/10
- https://mc.ai/machine-learning-vs-deep-learning-5/
- https://dev.to/overrideveloper/machine-learning-at-a-glance-1 108